

# Percona xTRAdb cLUSERT 运维实践

Sohu 徐国强



### | XtraDB Cluster 特征

#### 1, 同步复制

复制动作是同步的,实际上数据并不是完全同步的, 数据的同步存在一个间隙,只能称为虚同步。

#### 2, 多master

每一个节点都可以作为master,并将改动发送到其他 节点。

#### 3, 并行复制

复制可以指定多个线程,并且复制是以事务为单位的,多个事务同时并行推送到所有集群节点。

#### 4,新节点自动部署

只需要修改合适的参数,启动新节点的mysqld进程并成功加入集群后,数据完全自动的部署到新节点。

#### 5,数据一致性

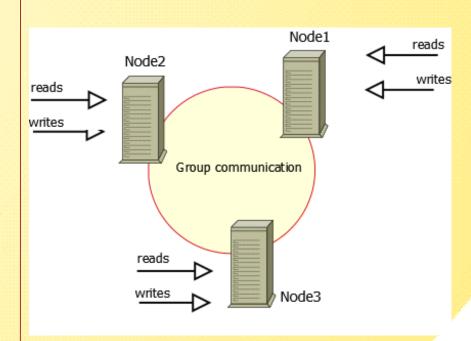
严格的数据一致

#### 6, 高可用性

单点故障不影响可用性

#### 7,与传统mysql几乎完全兼容

数据可以直接使用不需要任何转换,程序上也仅仅事务处理机制有变化,并且还可以完全规避



### XtraDB Cluster 缺陷

- 1,默认工作在InnoDB引擎表上,因此对其他引擎的表支持的很差,甚至根本不支持,所以不要考虑在PXC上使用MyISAM或者其他的存储引擎
- 2, 所有的表都必须要有主键
- 3,不支持的操作: LOCK/UNLOCK TABLES、 lock functions (GET\_LOCK(), RELEASE\_LOCK()...)
- 4, query log日志不能存放在表里面,必须存放在文件
- 6,由于集群是基于乐观的并发控制 (optimistic concurrency control),事务冲突的情况可能会在commit阶段发生
- 7,不支持XA事务,因为XA事务有可能在commit的时候出现异常发生 rollback
- 8,整个集群的吞吐量/性能取决于最慢的那个节点(成本)
- 9, 最小建议的集群节点数为3, 否则很容易产生脑裂(成本)
- 10,加入新节点,开销大,有多少个节点就有多少重复的数据
- 11,不能有效的解决写缩放问题,所有的写操作都将发生在所有节点上

### XtraDB Cluster 性能--测试环境

- 1, PXC 和 Master-Slave 均为3个节点
- 2, SAS、SSD 磁盘
- 3, Percona XtraDB Cluster 5.5.28
- 4, Percona Sever 5.5
- 5, Oracle Linux 6.3
  - 2.6.39-200.24.1.el6uek.x86\_64
- 6, DELL R710
  - CPU Xeon 5620 \* 2
  - Memory 64GB
- 7, Sysbench
- 8, haproxy和LVS

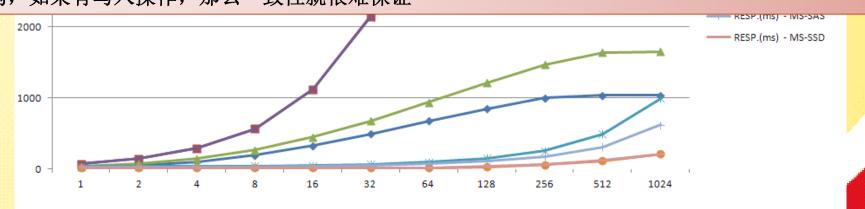


### XtraDB Cluster 性能—LVS只读测试

6000

可以看到随着并发线程数的增加,三节点的只读操作:

- 1,在使用SSD磁盘的情况下,PXC与MS结构的查询性能基本一致,偶有误差也基本保持在一个数量级上; SAS盘时,PXC性能会弱小一些
- 2,从响应时间上来看,也差不多是这个情况
- 3,但是在实际的应用中,如果达到了100个实时活动的连接,那么系统就已经非常繁忙了,MasterSlav结构,如果有写入操作,那么一致性就很难保证

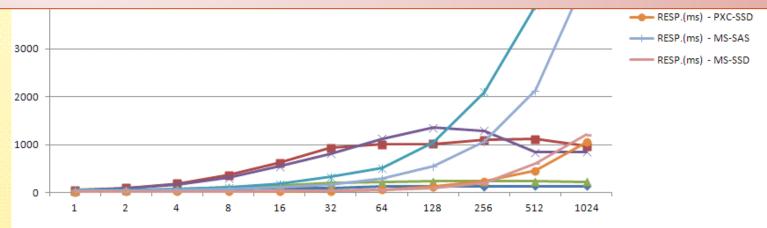


### XtraDB Cluster 性能—LVS单节点写测试

9000

PXC的写入性能是公开的表示了会比较差,这个差的比例约会低下1/4,但是如果使用了SSD磁盘,则会有较大的改观,但是依然会保持比较差的总体状况,具体原因后续会有分析:

- 1,PXC整体上落后MS结构
- 2,响应时间也是同样落后一些
- 3,SSD磁盘会带来相当大的提升

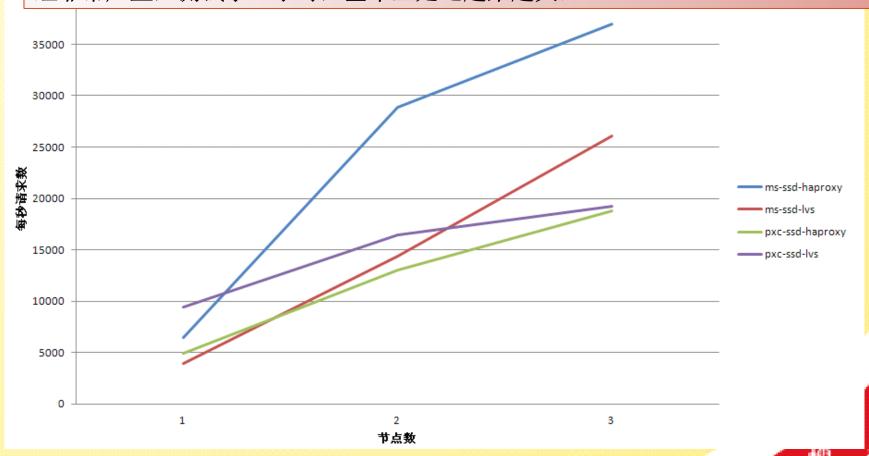


### XtraDB Cluster 性能—业务模拟测试

- ■1, 同时启2个sysbench, 一个只读, 另一个只写
- ■2,写请求只发送到某一个固定节点,读请求负载均衡到集群环境的所有节点
- ■3, 2个sysbench的读写请求数比例设置约为9: 1, 保证测试时间约等于或大于1小时
- ■4, 数据量为1.5亿
- ■6,依次对pxc/ms,lvs/haproxy各种环境进行测试,共4项: pxc-ssd-lvs, pxc-ssd-haproxy, ms-ssd-lvs, ms-ssd-haproxy
- ■7, ms测试导致主备不同步,暂时忽略其对测试的影响。需等待ms同步后再进行下一项测试
- ■8, 分别对集群环境中存在单节点、2节点、3节点测试3组
- ■9,每组测试5轮。每秒请求数计算: SUM(读请求数+写请求数)/SUM(读执行时间+写执行时间), GROUP BY 测试项

### XtraDB Cluster 性能—业务模拟测试

如果排除延迟问题,MS确实比PXC的性能更好(但是实际情况下,MS的延迟已经非常严重,测试了一小时,基本上延迟越来越大)



# ■基于Galera实现

Percona的这个Cluster实际上就是基于Galera实现,添加了一些mysql的参数,并调用Galera的接口,这是整体的工作流程:

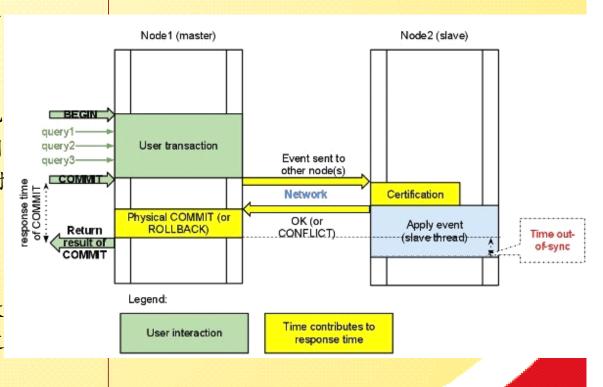
- 1,客户端提交MySQL数据库访问请求
- 2,通过wsrepAPI调用Galera将数据 变化复制到集群中其他节点

# ■数据复制流程(一)

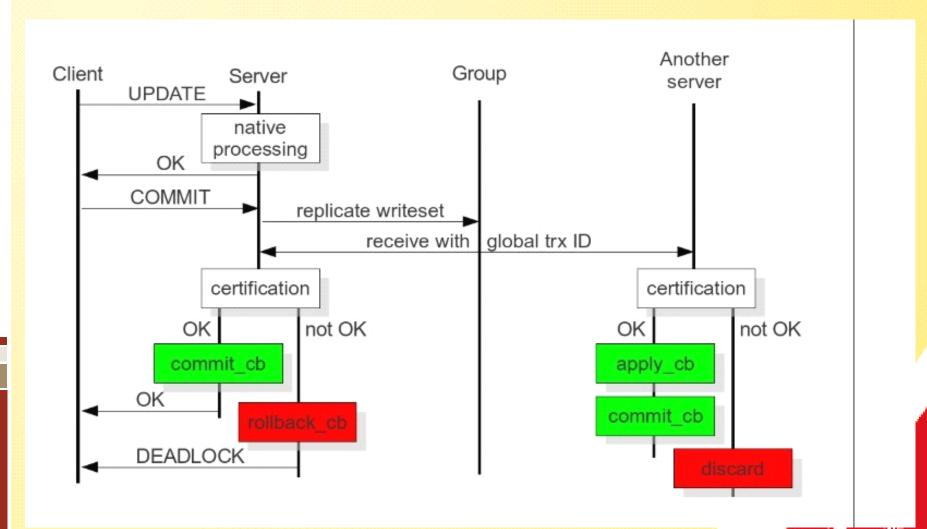
描述两个节点间的数据复制。

#### 要点:

- 1,只有当发生Commit操作时,才 发送数据验证请求到其他节点。
- 2,传输/返回验证数据时间和其他 节点的数据验证时间,将影响到 前数据操作节点真正commit的时 刻。
- 3, 其他节点只要验证成功了, 就 会返回成功的信号, 即使当前数 并没有真正的写入当前节点, 这 时间内, 将造成数据的不一致。



# ■ 数据复制流程(二)





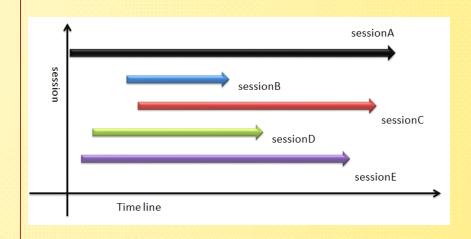
# ■数据复制流程(三)

根据前面描述的数据复制流程,可以得到这样的结论:

当多个事务同时操作相同的数据资源时,这个资源在集群中是不受任何一个Session 影响的,直到有一个Session对这个数据资源进行了成功的Commit操作,这时,其他的Session的所有操作实际上已经不可能成功了,当其他的事务尝试做Commit,会直接返回一个因为deadlock事务失败回滚的信息。

这与mysql默认的机制不同,在mysql innodb默认的情况下,当我们在其他事务中 对某个id的数据进行update;此时我们发起 一个事务对这个数据进行需要获得排它锁 的操作,操作将会进行等待,直到超时失 败或者现在持有排它锁的事务提交,当前 事务将继续。

(注意: 这里的每个Session来源于不同节点,单节点的死锁机制遵循mysql innodb默认的工作模式)



那么上图的session中,那些会成功呢?

只有SessionB



### ■节点状态变化

节点变化过程中用到的部分术语:

#### **SST** (State Snapshot Transfer)

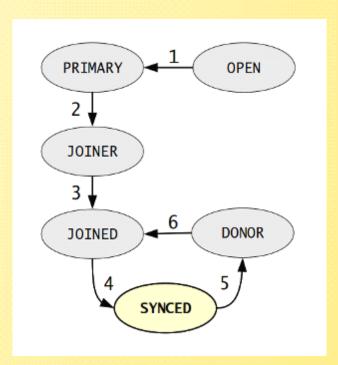
用于节点间传送数据,发生在节点初始化,或者节点故障需要全部重置数据的时候,相当于整个copy一份数据到新节点,这个过程影响非常大,会造成Donor节点的无法访问

#### **IST** (Increment Snapshot Transfer)

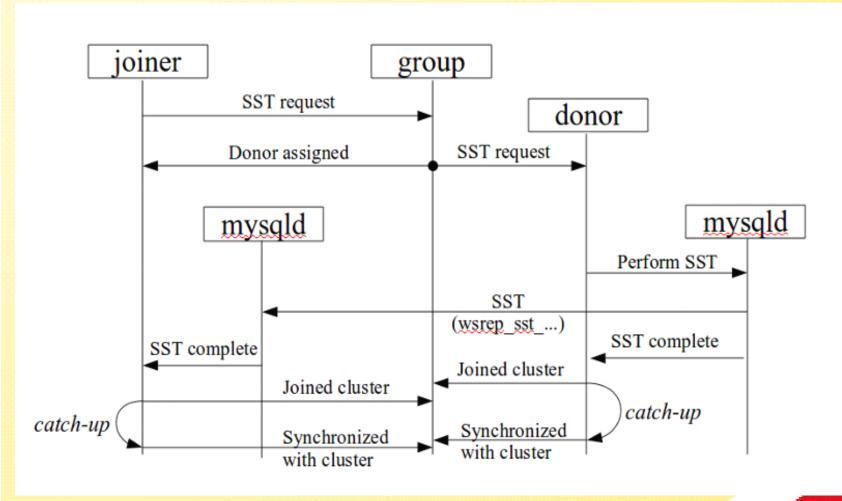
用于节点间传送数据,发生在节点初始化,或者节点故障,但是能够从galera.dat中获得增量同步点的情况,仅仅做必要的增量同步,是最理想的数据恢复方法。

#### Donor

当发生SST时,集群中被选中作为数据源的节点,可以手动指定也可以自动选择,被选中为Donor的节点可以进行Select,但是新的数据变化情况无法被应用,会被缓存在当前节点的cache文件中。当SST过程结束,Donor节点将变为JOINED状态,并应用这些缓存的内容,从而返回SYNCED状态。



# 新节点加入流程





# 名词解释

- Global Transcation ID (GTID)
  - □ 当通过客户端对数据库进行有顺序的一系列修改时(不一定仅仅是数据库),集群中所有的节点都对这个修改动作进行同步。在wsrep API中,通过GTID对这个修改进行标识,从而在所有节点达到一致。GTID由俩部分组成,一个标识对象的UUID,和一个标识这次修改状态的sequence(对应每一个动作),例如: 45eec521-2f34-11eo-0800-2a36050b826b:94530586304
- State Snapshot Transfer (SST)
  - □ 节点初始化/重做方法,使用指定的sst策略,来做数据的全量同步。
- Incremental State Transfer(IST)
  - □ Galera 2.x 开始支持。当一个节点加入,他当前的GUID与现集群相同,且缺失的数据能够在donor的Writeset的cache中找到,则可以进行IST,否则只能全部初始化数据,进行SST(State Snapshot Transfer)。

### SST方式的选择

#### MySQL Dump

- □ 需要锁定Donor节点, 无法提供访问
- □速度慢

#### Rsync

- □ 需要锁定Donor节点, 无法提供访问
- □ 速度快

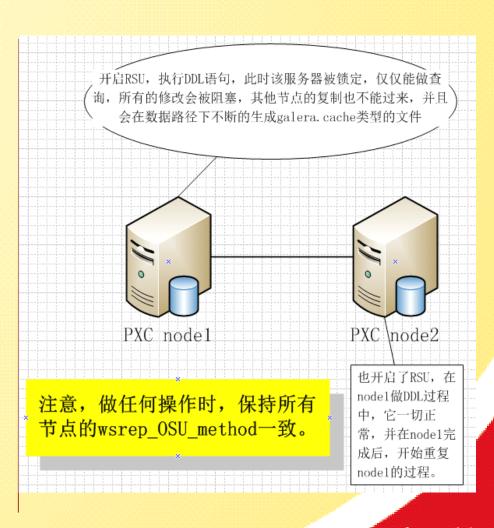
#### Xtrabackup

- □ 只需要短时间锁定Donor, 基本不影响访问
- □ 速度较快

# Rolling Schema Upgrade

Schema Upgrade指的是任何修改数据库结构的DDL语句,这种语句不具有事务性。 Total Order Isolation(TOI) 默认的工作方式,在这种模式下,DDL语句的表现将和在一个单机数据库上一样,将会锁定整个集群库。并且这个语句将会同时发送到所有的集群节点去执行。

Rolling Schema Upgrade(RSU) wsrep是通过设置 wsrep\_OSU\_method参数,DDL语句 将会在当前节点执行,并且在执行过程中不锁定其他节点,当这个节点的DDL操作完成,将会应用操作过程中延迟的replication,然后你在手工的一个一个节点的去做DDL操作。这个滚动升级的过程中,集群中会有部分服务器有新的表结构,部分有旧的表结构。



# 节点故障

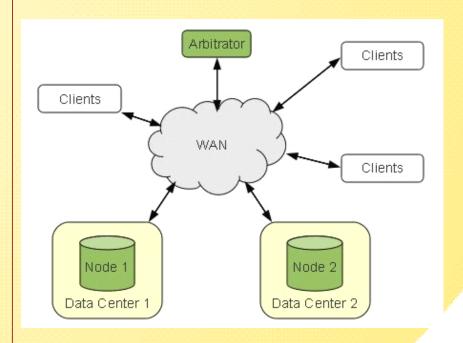
- 任何的硬件故障、软件崩溃、网络连接异常,都将造成节点故障。判断故障节点的依据,是根据他是否还能够连接PC (Primary component) ,而PC是从当前集群中随机选择的,因此不能简单的根据服务器是否能够ping通等外部的方式来判断,需要根据各个节点的wsrep\_local\_state来进行投票。
- 故障侦测节点每隔 evs.inactive\_check\_period接收一次数据包。假如在 evs.keepalive\_period间隔都没有任何信息发出,则发出一个heartbeat信号。假如某一个节点在evs.suspect\_timeout都没有任何信息发出,则这个节点被标识为 suspected, 当所有的cluster成员节点都认为这个节点是suspected,则认为这个节点failed。同理,假如某个节点认为另一个节点有问题,则也必须所有的节点都保持一致的想法,才能够定性。
- 综上,这些节点状态参数的设置应该遵循:

evs.keepalive\_period <= evs.inactive\_check\_period <= evs.suspect\_timeout <= evs.inactive\_timeout <= evs.consensus\_timeout

### Galera Arbiter

o.8.2的Galera开始支持一个 Arbitrator节点,来预防脑裂(splitbrain);在如下图的情况下,如果 有其中一个node无法正常连接 WAN,那么另外一个node仍然可 以通过和Arbitrator的联系来确认状 态正常,并且继续提供服务。

需要注意的是,Arbitrator需要能够看到所有的网络流量,尽管它不用这些数据做任何事,因此,它会给网络带来额外的压力。



### 部分参数调整

- 当网络状况不好时考虑调整的参数设置:
  - wsrep\_provider\_options = "evs.keepalive\_period = PT3S; evs.inactive\_check\_period = PT1oS; evs.suspect\_timeout = PT3oS; evs.inactive\_timeout = PT1M; evs.consensus\_timeout = PT1M"
    - evs.keepalive\_period 参数控制多久发送一次keepalive请求信号
    - evs.inactive\_check\_period 参数控制多久检测一次节点活动/静止状态
    - evs.suspect\_timeout参数控制某个节点是否被标识为suspected状态的时间间隔
    - evs.inactive\_timeout参数控制节点不活动时检测周期
    - evs.consensus\_timeout 参数控制多久检测一次节点一致性 通过上面的设置,可以使节点超时时间为30秒
    - evs.inactive\_timeout参数必须不小于evs.suspect\_timeout, evs.consensus\_timeout必须不小于evs.inactive\_timeout。
- wsrep\_slave\_threads
  - □ 建议每个core启动4个复制线程,这个参数很大程度上受到I/O能力的影响,官方甚至在ThinkPad R51一个4200转硬盘、单核心的机器上设置32个线程,并且执行良好。可以通过观察wsrep\_cert\_deps\_distance这个状态变量来获得当前最佳的线程数,这个参数实际上表示单位时间平均多少个writesets能被执行掉。

### 监控要点

#### wsrep\_flow\_control\_paused

立个变量标识当前节点落后于集群的程度,0.0-1.0,0.0为没有落后,1.0为flow control已经停止了。应该尽量保证这个变量值为0.0。如果落后实在太厉害,则应该适当增加复制线程数wsrep\_slave\_threads,如果还没有改善,则应该从集群中删除最慢的节点。

#### wsrep\_cert\_deps\_distance

立个变量标识当前节点平均时间内并行执行的事务数,这个数据可以用来作为wsrep\_slave\_threads的参考,同时当并发量很高的时候,这个数值也会很大。

#### wsrep\_flow\_control\_sent

表示flow\_control发出FC\_PAUSE事件的次数,暂停的次数越多,表示接受到的请求频繁堵满slave队列,这种情况下不是队列 长度不足,就是机器性能太差。(如果集群中多个机器都有这个情况,则考虑调整slave队列长度的相关参数,如 qcs.fc\_limit等)

#### wsrep\_local\_recv\_queue\_avg

□ 这个参数表示本地节点平均的接收队列长度,如果这个参数不为0.0,则表示接收来的数据不能被及时应用(立即应用了则不会进入队列)。

#### wsrep\_local\_send\_q\_avg

□ 这个参数表示本地节点发送数据的队列长度,如果这个参数不为0.0,则表示向外发送数据的速度比较慢,有堆积。

### 高负载下的宕机风险

- 利用sysbench通过Haproxy对三节点的Cluster进行并发读写,并发线程数300。
- 此时,整体每个节点的IO负载都比较低,没有造成瓶颈,但是CPU资源消耗很大

```
top = 16:17:25 up 7 days, 23:13, 3 users, load average: 34.75, 36.71, 36.10
Tasks: 204 total, 1 running, 203 sleeping, 0 stopped, 0 zombie
Cpu(s): 23.7%us, 7.4%sy, 0.0%ni, 67.9%id, 0.2%wa, 0.0%hi, 0.7%si, 0.0%st
Mem: 99191560k total, 80784640k used, 18406920k free, 245752k buffers
Swap: 16777212k total, 749988k used, 16027224k free, 28815004k cached
```

PID USER PR NI VIRT RES SHR S %CPU %MEM TIME+ COMMAND 24807 mysql 20 0 37.9g 21g 137m S 1158.6 22.7 526:35.37 mysqld



### 高负载下的宕机风险

- 此时三个节点的日志中均频繁出现如下内容。
- 此时发生过一次三个节点均无法通信,导致脑裂,三个节点均变 为只读状态的故障。
- 同时观察wsrep\_\*的相关状态参数,发现了wsrep\_cert\_deps\_distance的值,与集群的稳定性息息相关。在当时的测试情况下,当该值超过1300,则集群崩溃的可能性非常大。
- 这种宕机一般不会引起数据丢失和不一致,但是将会终止数据库的可用性。

```
120914 15:57:12 [Note] WSREP: (ee0487b2-fe18-11e1-0800-e7ec3335ef5d, 'tcp://10.10.59.229:5030') reconnecting to 6d0f9357-fe1f-11e1-080 120914 15:57:12 [Note] WSREP: (ee0487b2-fe18-11e1-0800-e7ec3335ef5d, 'tcp://10.10.59.229:5030') turning message relay requesting off 120914 15:59:13 [Note] WSREP: (ee0487b2-fe18-11e1-0800-e7ec3335ef5d, 'tcp://10.10.59.229:5030') turning message relay requesting on, n 120914 15:59:13 [Note] WSREP: (ee0487b2-fe18-11e1-0800-e7ec3335ef5d, 'tcp://10.10.59.229:5030') turning message relay requesting off 120914 16:03:05 [Note] WSREP: (ee0487b2-fe18-11e1-0800-e7ec3335ef5d, 'tcp://10.10.59.229:5030') turning message relay requesting on, n 120914 16:03:06 [Note] WSREP: (ee0487b2-fe18-11e1-0800-e7ec3335ef5d, 'tcp://10.10.59.229:5030') turning message relay requesting off 120914 16:03:32 [Note] WSREP: (ee0487b2-fe18-11e1-0800-e7ec3335ef5d, 'tcp://10.10.59.229:5030') turning message relay requesting on, n 120914 16:03:33 [Note] WSREP: (ee0487b2-fe18-11e1-0800-e7ec3335ef5d, 'tcp://10.10.59.229:5030') turning message relay requesting on, n 120914 16:03:33 [Note] WSREP: (ee0487b2-fe18-11e1-0800-e7ec3335ef5d, 'tcp://10.10.59.229:5030') reconnecting to 6d0f9357-fe1f-11e1-0800-e7ec3335ef5d, 'tcp://10.10.59.229:5030') reconnecting to 6d0f9357-fe1f-11e1-0800-e7ec3335ef5d, 'tcp://10.10.59.229:5030')
```

### 高负载引起宕机风险的防治

- 参考建议的监控数据,严格控制
- 对应用的入口SQL详细审核,避免不正常的 SQL运行
- 使用一些策略,例如lptables限制单位时间 的并发量、包个数、来避免宕机

# 节点故障与恢复

- 任何的硬件故障、软件崩溃、网络连接异常,都将造成节点故障。判断故障节点的依据,是根据他是否还能够连接PC (Primary component) ,而PC是从当前集群中随机选择的,因此不能简单的根据服务器是否能够ping通等外部的方式来判断,需要根据各个节点的wsrep\_local\_state。
- 前面说过,故障侦测节点每隔 evs.inactive\_check\_period接收一次数据包。假如在 evs.keepalive\_period间隔都没有任何信息发出,则发出一个heartbeat信号。假如 某一个节点在evs.suspect\_timeout都没有任何信息发出,则这个节点被标识为 suspected, 当所有的cluster成员节点都认为这个节点是suspected,则认为这个节点failed。同理,假如某个节点认为另一个节点有问题,则也必须所有的节点都 保持一致的想法,才能够定性。
- 综上,这些节点状态参数的设置应该遵循: evs.keepalive\_period <= evs.inactive\_check\_period <= evs.suspect\_timeout <= evs.inactive\_timeout <= evs.consensus\_timeout</li>

# 节点故障与恢复

- 一旦节点发生故障,分不同的情况,如果无法进行IST,则需要做SST, 即需要进行完全的state snapshot transfer,代价非常巨大。
- Donor选择:有自动选择和手动指定Donor两种方式,通过 wsrep\_sst\_donor= DONOR\_NAME来指定,不指定则在当前集群中随机选 择。
- 需要注意的是,当某个node被选为Donor时,如果使用Rsync或者 Dump,这个节点是不能提供客户端服务的,即使使用Xtrabackup这个节点的性能和稳定性也会受到很大影响,基于这种情况,建议手动选择一个Donor,避免高负载的机器被用来做Donor。

# 节点故障与恢复

- 节点故障后获取GTID的方法
  - 执行mysqld加--wsrep-recover参数,可获得 GTID,如
    - mysqld --defaults-file=/DATA/my6ooo/my6ooo.cnf -log\_error=/dev/stdout --wsrep-recover
    - 再调用--wsrep\_start\_position=设置GTID,启动mysqld

■ 默认情况下,目前的版本似乎会自动这样做,看源码是从innodb redolog记录的 checkpoint里获得的GTID

搜 狐

谢谢

完